

---

# Estudio de Reacciones Públicas en Redes Sociales durante Desastres Naturales en Puerto Rico

---

**Sebastián H. Jansasoy Molina**  
Universidad de Puerto Rico, Mayagüez  
sebastian.jansasoy@upr.edu

**Marco Yu Cordero**  
Universidad de Puerto Rico, Mayagüez  
marco.yu@upr.edu

**Taix Pacheco García**  
Universidad de Puerto Rico, Mayagüez  
taix.pacheco@upr.edu

**Sebastian Hernandez Acevedo**  
Universidad de Puerto Rico, Mayagüez  
sebastian.hernandez10@upr.edu

## Abstract

Los desastres naturales provocan una notable actividad en redes sociales, generando tanto información crítica como contenido irrelevante o emocional. Este estudio presenta un análisis automatizado de tweets relacionados con el huracán María en Puerto Rico, dirigido a mejorar la gestión informativa durante emergencias. Inicialmente, se clasificaron los tweets en tres categorías—*informativos*, *no informativos* y *neutrales*—utilizando técnicas avanzadas de procesamiento de lenguaje natural (NLP), métodos clásicos de aprendizaje supervisado y redes neuronales profundas. Posteriormente, se realizó un análisis de sentimientos para determinar el tono emocional predominante en las publicaciones. Los resultados experimentales indican que los modelos supervisados, especialmente la regresión logística y redes neuronales simples, lograron altos niveles de precisión en la identificación de contenido relevante. Este enfoque evidencia su potencial para aplicaciones prácticas en tiempo real y establece una base sólida para futuras investigaciones que incorporen técnicas avanzadas de aprendizaje profundo y análisis multimodal.

## 1. Introducción

Puerto Rico, debido a su ubicación geográfica y condiciones climáticas, es particularmente vulnerable a desastres naturales como huracanes, terremotos y tsunamis. Estos eventos ocasionan daños físicos y sociales significativos, además de generar una notable actividad en plataformas digitales, especialmente en redes sociales como Twitter (1). Durante estas situaciones de crisis, los usuarios suelen compartir tanto información crítica y solicitudes de ayuda como mensajes irrelevantes o desinformativos (2). Esta gran cantidad de datos, generados espontáneamente y en tiempo real, plantea simultáneamente una oportunidad y un desafío para los equipos encargados de gestionar emergencias (3; 4).

Ante esta situación, se hace evidente la necesidad de desarrollar sistemas automatizados capaces de filtrar, clasificar y priorizar eficazmente la información relevante. En este proyecto se presenta un enfoque basado en técnicas de *machine learning* para clasificar automáticamente publicaciones de Twitter relacionadas con el huracán María en Puerto Rico. La clasificación propuesta se realiza en tres categorías fundamentales: **informativos**, **no informativos** y **neutrales** (4). El objetivo principal es optimizar el procesamiento y análisis de grandes volúmenes de datos textuales en tiempo real, facilitando así la toma de decisiones oportunas, la coordinación eficiente de recursos y la intervención humanitaria efectiva.

Para lograr este objetivo, se emplearon técnicas avanzadas de procesamiento de lenguaje natural (NLP), modelos clásicos de aprendizaje supervisado—tales como Naive Bayes, Máquinas de Vectores

de Soporte (SVM) y Regresión Logística—además de redes neuronales profundas. Complementariamente, se realizó un análisis de sentimientos con el fin de profundizar en la comprensión emocional de los mensajes (5; 6; 7).

El presente documento detalla la metodología utilizada, los experimentos desarrollados y los resultados obtenidos, proporcionando un análisis exhaustivo del desempeño, ventajas y limitaciones de cada modelo implementado. La contribución principal del estudio es demostrar la efectividad de estos métodos computacionales para apoyar la gestión de crisis, destacando particularmente su aplicabilidad en contextos sociolingüísticos específicos como el de Puerto Rico.

## 2. Antecedentes

El análisis automatizado del contenido en redes sociales, particularmente Twitter, se ha convertido en una herramienta clave para estudiar fenómenos comunicativos y sociales durante desastres naturales. La integración de técnicas avanzadas de procesamiento de lenguaje natural (NLP) con modelos de aprendizaje automático permite identificar patrones de comportamiento, detectar necesidades humanitarias emergentes y evaluar rápidamente la opinión pública. Estas capacidades son especialmente valiosas en contextos de emergencia, donde la información estructurada es escasa y las decisiones deben tomarse rápidamente.

Un referente metodológico destacado en esta área es el corpus *HumAID*, desarrollado por Alam et al. (3). Este conjunto de datos comprende más de 7,000 tweets anotados manualmente y recopilados durante 19 desastres naturales ocurridos entre 2016 y 2019, clasificados en 11 categorías humanitarias. El corpus no solo ofrece diversidad geográfica y temática, sino que también incluye evaluaciones comparativas usando modelos clásicos (SVM, Random Forest) y enfoques modernos (Transformers, FastText), estableciendo un punto de referencia sólido para futuras investigaciones.

En el contexto particular de Puerto Rico, el trabajo de Bogemann et al. (1) es especialmente relevante, al analizar más de 330,000 tweets relacionados con eventos significativos como los terremotos de enero de 2020 y el huracán María en 2017. Este estudio explora diferencias en el comportamiento digital durante eventos imprevistos versus anticipados, utilizando técnicas avanzadas como modelado de tópicos (LDA), análisis temporal y geolocalización de mensajes. Este enfoque resalta la necesidad de adaptar las herramientas de análisis a contextos socioculturales específicos, como el Caribe.

De manera complementaria, Alam et al. (2) proponen un enfoque multimodal que combina la clasificación textual y visual durante los huracanes Harvey, Irma y María. Mediante clasificadores supervisados (Random Forest) y no supervisados (LDA), junto con técnicas de reconocimiento de entidades nombradas (NER) y redes convolucionales para imágenes, este estudio logra una evaluación más completa y efectiva en contextos con gran volumen de datos no estructurados.

Otro recurso relevante es el *Disaster Tweet Corpus 2020*, presentado por Wiegmann et al. (4), que incluye más de 123,000 tweets anotados de 46 desastres naturales diferentes. Este corpus permite evaluar el rendimiento de modelos avanzados como CNN, BERT y USE, demostrando que los modelos generales (como USE) suelen tener mejor capacidad de generalización, mientras que los modelos especializados logran un mejor rendimiento cuando disponen de información contextual previa.

Además del análisis temático, diversos estudios recientes se han enfocado en el análisis de sentimientos durante crisis sanitarias globales. Por ejemplo, Naseem et al. (5) desarrollaron el conjunto de datos *COVIDSenti*, con más de 90,000 tweets etiquetados, mostrando la superioridad de modelos basados en Transformers, como BERT, en tareas de clasificación emocional. En una línea similar, Imamah y Rachman (6) utilizaron TF-IDF y regresión logística sobre un corpus de 350,000 tweets, obteniendo una precisión destacable.

En relación al preprocesamiento textual, Zhao y Xiaolin (8) compararon diversas técnicas tales como lematización, normalización, eliminación de palabras irrelevantes (stopwords) y manejo de negaciones, concluyendo que estos factores impactan significativamente la efectividad de los modelos.

Finalmente, en el campo del análisis emocional, Imran et al. (7) emplearon modelos basados en LSTM para identificar emociones y polaridad en tweets relacionados con la COVID-19, destacando las variaciones culturales en la expresión emocional. Por otro lado, Cofas et al. (9) investigaron la evolución de opiniones sobre vacunación mediante técnicas avanzadas de clasificación multiclase,

redes semánticas y modelado de tópicos, estableciendo así un marco analítico para monitorear la dinámica discursiva post-crisis.

En conjunto, estos estudios proporcionan un marco empírico y metodológico robusto para el análisis automatizado del contenido digital en situaciones de emergencia, demostrando la utilidad de enfoques supervisados, multimodales y lexicográficos para mejorar la respuesta frente a desastres naturales.

### 3. Metodología

#### 3.1. Conjuntos de Datos

- **HumAID Hurricane María Dataset:** Proveniente del repositorio CrisisNLP, este conjunto contiene más de 7,300 tweets anotados manualmente en categorías humanitarias como *pre-caución y consejos*, *personas desplazadas*, *infraestructura dañada* o *solicitudes urgentes*. Su estructura etiquetada lo hace particularmente adecuado para tareas iniciales de clasificación supervisada realizadas exclusivamente con este dataset (3).
- **HumAID Additional Hurricanes Dataset:** Proveniente también del repositorio CrisisNLP (ICWSM 2021), este conjunto ampliado incluye aproximadamente 34,000 tweets anotados provenientes de múltiples desastres relacionados con huracanes adicionales. Estos datos se combinaron posteriormente con los del huracán María para mejorar la capacidad generalizadora y el rendimiento final de los modelos evaluados. Los huracanes incluidos son:
  - **Huracán Dorian (2019):** Tweets anotados compartiendo subcategorías comunes con el dataset del huracán María.
  - **Huracán Florence (2018):** Tweets anotados compartiendo subcategorías comunes con el dataset del huracán María.
  - **Huracán Harvey (2017):** Tweets anotados compartiendo subcategorías comunes con el dataset del huracán María.
  - **Huracán Irma (2017):** Tweets anotados compartiendo subcategorías comunes con el dataset del huracán María.
  - **Huracán Matthew (2016):** Tweets anotados compartiendo subcategorías comunes con el dataset del huracán María.

#### 3.2. Pipeline metodológico

El presente trabajo implementa un pipeline integral para el análisis automatizado de publicaciones en Twitter durante desastres naturales, centrado inicialmente en el huracán María y luego ampliado con datos de otros eventos. La estrategia combina técnicas de procesamiento de lenguaje natural, aprendizaje automático supervisado y visualización exploratoria, con el fin de clasificar tanto la utilidad informativa como la carga emocional de los tweets. A continuación, se describen las etapas clave de este flujo de trabajo. idad generalizadora del modelo.

#### 3.3. Preprocesamiento del Texto

El preprocesamiento del texto se realizó en los siguientes pasos:

1. Conversión de textos a minúsculas.
2. Eliminación de URLs, menciones a usuarios (@usuario), hashtags y caracteres especiales.
3. Remoción de números y signos de puntuación.
4. Tokenización y lematización para simplificar y estandarizar el vocabulario.

Estos pasos garantizaron una representación textual más limpia y eficiente para la extracción de características en etapas posteriores.

### 3.4. Análisis Exploratorio

Se llevó a cabo un análisis exploratorio inicial mediante visualizaciones gráficas como histogramas, nubes de palabras y distribución de clases. Este análisis permitió detectar un notable desbalance en las clases, destacándose la clase *informativo* como mayoritaria.

### 3.5. Vectorización del Texto

Para transformar los textos en vectores numéricos adecuados para los modelos, se emplearon dos técnicas principales:

- **Bolsa de Palabras (BoW)** con unigramas y bigramas.
- **TF-IDF**, para ponderar la relevancia relativa de los términos en el corpus.

Estas técnicas facilitaron la aplicación efectiva de algoritmos supervisados.

### 3.6. Modelado y Clasificación

Se compararon múltiples clasificadores clásicos:

- Naive Bayes Multinomial
- Máquinas de Vectores de Soporte (SVM)
- Regresión Logística

Además, se desarrollaron redes neuronales profundas, comenzando con una arquitectura simple y posteriormente mejorada mediante técnicas avanzadas de regularización (*dropout* y L2) y ajuste de pesos por clase para abordar el desbalance en los datos.

### 3.7. Evaluación de Modelos

Los modelos fueron evaluados mediante métricas estándar:

- Matriz de confusión
- Precisión, Recobrado (*Recall*) y F1-score por clase
- F1-score macro, ideal para conjuntos de datos desbalanceados

### 3.8. Análisis de Sentimiento

Adicionalmente, se implementó un análisis de sentimiento usando VADER para identificar y evaluar la carga emocional predominante en tweets clasificados como *informativos*.

### 3.9. Reproducibilidad y Documentación

Todos los experimentos se llevaron a cabo en Google Colab y se documentaron detalladamente. Se emplearon bibliotecas especializadas tales como Scikit-learn, TensorFlow/Keras, Matplotlib, Seaborn y NLTK, asegurando replicabilidad y claridad metodológica.

Esta metodología integral sienta las bases para futuras aplicaciones avanzadas, como modelos basados en Transformers y análisis en tiempo real.

## 4. Resultados

### 4.1. Modelos clásicos

La Tabla 1 resume el rendimiento general obtenido por los modelos clásicos evaluados en este estudio.

Cuadro 1: Rendimiento de modelos clásicos.

| Modelo                                     | Accuracy    | F1 macro    |
|--------------------------------------------|-------------|-------------|
| Naive Bayes (BoW unigramas)                | 0.88        | 0.58        |
| SVM (TF-IDF)                               | 0.88        | 0.61        |
| <b>Regresión Logística (BoW unigramas)</b> | <b>0.89</b> | <b>0.61</b> |

De estos, el mejor modelo clásico fue la **Regresión Logística**, por lo que se presenta a continuación la matriz de confusión (Figura 1) y el desglose de precisión por clase (Figura 2).




Figura 1: Matriz de confusión - Regresión Logística.




Figura 2: Precisión por clase - Regresión Logística.

## 4.2. Redes neuronales

La Tabla 2 muestra el desempeño comparativo entre la red neuronal simple y la red mejorada con técnicas avanzadas.

Cuadro 2: Rendimiento de redes neuronales evaluadas.

| Modelo                                                 | Accuracy    | F1 macro    |
|--------------------------------------------------------|-------------|-------------|
| Red Neuronal Simple                                    | 0.89        | 0.60        |
| <b>Red Neuronal Mejorada (Dropout, L2, peso clase)</b> | <b>0.90</b> | <b>0.63</b> |

Las mejoras introducidas (regularización L2, *dropout*, ajuste por pesos de clase) contribuyeron significativamente a reducir el sobreajuste y mejorar la identificación de clases minoritarias. El mejor modelo neuronal, por tanto, es la **Red Neuronal Mejorada**, cuya matriz de confusión y precisión por clase se presentan en las Figuras 3 y 4, respectivamente.




Figura 3: Matriz de confusión - Red Neuronal Mejorada.




Figura 4: Precisión por clase - Red Neuronal Mejorada.

#### 4.3. Comparación de Modelos

Finalmente, en la Tabla 3 se realiza una comparación directa entre el mejor modelo clásico (Regresión Logística) y el mejor modelo neuronal (Red Neuronal Mejorada).

Cuadro 3: Comparación final entre modelos seleccionados.

| Modelo                       | Accuracy    | F1 macro    |
|------------------------------|-------------|-------------|
| Regresión Logística          | 0.89        | 0.61        |
| <b>Red Neuronal Mejorada</b> | <b>0.90</b> | <b>0.63</b> |

La **Red Neuronal Mejorada** se selecciona finalmente como el modelo óptimo debido a su rendimiento superior en métricas globales y una mejor capacidad para manejar clases desbalanceadas, resultado de técnicas avanzadas de regularización y ajuste de pesos por clase. Este modelo no solo

supera ligeramente a la regresión logística en términos de precisión general y F1-score macro, sino que también presenta mejor robustez y estabilidad frente al sobreajuste, lo que lo hace más adecuado para aplicaciones prácticas en tiempo real.

#### 4.4. Impacto del aumento de datos

La incorporación de datos adicionales provenientes de múltiples huracanes (Dorian, Florence, Harvey, Irma, Matthew) permitió evaluar y mejorar significativamente la capacidad de generalización de los modelos. Los resultados revelaron que el entrenamiento con un conjunto de datos más amplio y variado condujo a una mejora en la robustez y estabilidad de los modelos, particularmente en la identificación de contenido informativo y neutral.

#### 4.5. Efecto del preprocesamiento avanzado

El preprocesamiento riguroso aplicado, que incluyó limpieza exhaustiva de caracteres especiales, eliminación de *stopwords* y lematización, contribuyó considerablemente a mejorar la calidad semántica del texto y, por ende, la precisión de los modelos. Esto facilitó una representación más limpia y consistente, reflejada en el incremento del rendimiento observado tras aplicar estos pasos adicionales.

#### 4.6. Análisis final de la generalización

El modelo neuronal mejorado demostró ser especialmente eficaz al utilizar datos ampliados, logrando un rendimiento generalizado consistente a través de distintos eventos naturales. Esto sugiere que la incorporación de técnicas avanzadas como *dropout*, regularización L2 y ajuste de pesos por clase resultan fundamentales para enfrentar desafíos de generalización y desbalance en contextos reales y variados.

### 5. Análisis Complementario: Árboles de Decisión, Noticias y Terremotos

Como parte de la expansión del estudio, se desarrollaron dos análisis adicionales complementarios. El primero consistió en evaluar el desempeño de modelos **Decision Tree** y **Random Forest** sobre los tweets del huracán María del conjunto **ISCRAM18 Dataset** (2), clasificados manualmente en tres categorías: informativo, neutral y no informativo. Los mejores resultados se obtuvieron con Random Forest y representación BoW (1,1), alcanzando un F1 macro de 0.58 y accuracy de 0.91 (ver Figura 7, panel a).

El segundo análisis se centró en el estudio de titulares de **noticias** relacionadas tanto con el huracán María como con los terremotos de 2020 en Puerto Rico. Utilizando herramientas como GDEL y newspaper3k, se extrajeron titulares de artículos internacionales y se clasificaron automáticamente según polaridad emocional (con VADER) y relevancia informativa (etiquetado manual). Los modelos supervisados más efectivos para esta tarea fueron **Logistic Regression** y **SVM**, alcanzando F1 macro de hasta 0.63 para María y 0.86 para Terremotos. La Figura 7 (panel b) muestra la comparación de sentimiento entre ambos eventos.




Figura 5: \*

(a) Accuracy por modelo de árbol sobre tweets del Huracán María (ISCRAM18)




Figura 6: \*

(b) Distribución comparativa de sentimiento en titulares de noticias (María vs. Terremotos)

Figura 7: Resultados complementarios: clasificación supervisada con árboles de decisión y análisis emocional en noticias.

Estos análisis adicionales no solo confirman la aplicabilidad de modelos de árbol en tareas supervisadas con conjuntos limitados, sino que también extienden la comprensión del discurso informativo más allá de las redes sociales, incorporando fuentes periodísticas y eventos múltiples. Esto sienta las bases para futuras investigaciones multimodales que integren texto, imagen y contexto temporal.

## 6. Clasificación Supervisada con Random Forest e Ingeniería de Características

Como complemento al análisis principal, se desarrolló un segundo modelo supervisado mediante **Random Forest**, incorporando análisis de sentimiento, detección de urgencia y meta-características textuales.

El pipeline incluye limpieza de texto, vectorización TF-IDF, ingeniería de características semánticas (sentimiento con VADER, urgencia por palabras clave) y rasgos estructurales (longitud, signos, menciones). El entrenamiento se realizó sobre 26,002 tweets y la evaluación sobre 5,401.

El modelo alcanzó una **F1 macro de 0.358**, destacando en la clasificación de tweets informativos. La Figura 8 resume esta métrica, mientras que las Figuras 9 y 10 muestran la matriz de confusión y métricas por clase, respectivamente.




Figura 8: F1-macro global del modelo Random Forest.






Figura 9: Matrices de confusión: recuentos y porcentajes normalizados.




Figura 10: Precisión, recall y F1-score por clase.

Este enfoque destaca por su modularidad, capacidad de integración de múltiples señales y soporte para explicabilidad con SHAP, facilitando su futura aplicación en escenarios reales de monitoreo de crisis.

### 6.1. Recomendaciones

- **Optimizar hiperparámetros** y realizar *feature selection* automática.
- Implementar **técnicas de balanceo** como SMOTE para mejorar el recall en clases minoritarias.
- Extender la explicabilidad a modelos alternativos (e.g., Gradient Boosting, XGBoost).
- Comparar directamente con arquitecturas neuronales y transformers multilingües.

### 6.2. Comparación con Modelos Anteriores

En comparación con los modelos previos evaluados —incluyendo Naive Bayes, SVM, regresión logística y redes neuronales—, el modelo Random Forest con ingeniería de características obtuvo un

rendimiento moderado (F1 macro de 0.36), inferior al de la red neuronal mejorada (F1 macro de 0.63) y la regresión logística (F1 macro de 0.61). No obstante, su principal valor reside en la interpretabilidad y la integración de múltiples dimensiones semánticas (sentimiento, urgencia, estructura del tweet), lo que lo hace útil como herramienta exploratoria o base para sistemas explicables en contextos de respuesta ante emergencias.

## 7. Análisis de Sentimiento con RoBERTa sobre Tweets del Huracán María

Con el objetivo de ilustrar la aplicabilidad de modelos avanzados de análisis de sentimiento en contextos de desastres naturales, se utilizó el modelo preentrenado `cardiffnlp/twitter-roberta-base-sentiment-latest`, específicamente diseñado para texto informal en Twitter. Este modelo fue aplicado a los tweets del Huracán María, previamente procesados y anotados con categorías humanitarias del conjunto HumAID.

Cada tweet fue clasificado en una de tres categorías de sentimiento: *Positive*, *Neutral* o *Negative*, y se calculó un puntaje de **confianza** asociado a cada predicción. Esta dimensión emocional complementa los enfoques supervisados anteriores, proporcionando información valiosa para la priorización de mensajes en escenarios de emergencia.

La Figura 13 resume los resultados obtenidos. El panel (a) presenta la distribución de los niveles de confianza del modelo según el tipo de sentimiento asignado, mostrando que el modelo tiende a ser más confiado en clasificaciones *positive*. El panel (b) muestra la distribución porcentual del sentimiento por clase temática, destacándose una mayor prevalencia de sentimiento negativo en categorías asociadas a daños materiales o pérdidas humanas.




Figura 11: \*

(a) Confianza del modelo RoBERTa según el sentimiento predicho.




Figura 12: \*

(b) Distribución porcentual de sentimiento por clase temática (HumAID).

Figura 13: Análisis de sentimiento con RoBERTa sobre tweets del Huracán María: confianza por sentimiento (a) y distribución de sentimiento por clase temática (b).

Este enfoque demuestra cómo los análisis de sentimiento automatizados pueden integrarse directamente con esquemas de clasificación humanitaria existentes, proporcionando una visión más rica del discurso social durante eventos extremos y contribuyendo a una mejor toma de decisiones basada tanto en el contenido informativo como en el tono emocional de los mensajes.

## 8. Discusión

Los resultados obtenidos evidencian la efectividad y robustez del modelo neuronal mejorado frente a los modelos clásicos evaluados, particularmente en términos de precisión global y capacidad para manejar el desbalance significativo entre las categorías del conjunto de datos. La incorporación estratégica de técnicas avanzadas como la regularización L2, dropout y ajuste de pesos por clase resultó crucial para mitigar el sobreajuste y mejorar sustancialmente el desempeño predictivo del

modelo. Estos hallazgos confirman que las redes neuronales, cuando son adecuadamente regularizadas y ajustadas, poseen una ventaja notable para abordar tareas complejas de clasificación en contextos reales de crisis.

Adicionalmente, se evaluó un modelo complementario basado en **Random Forest** enriquecido con ingeniería de características semánticas (análisis de sentimiento y urgencia) y estructurales (longitud, puntuación, menciones), el cual demostró ser modular y fácilmente interpretable. Aunque su desempeño fue más modesto ( $F1_{macro}$  de 0.36), representa una alternativa viable en escenarios donde la transparencia, trazabilidad o tiempos de entrenamiento son prioritarios. Su integración con técnicas de explicabilidad como SHAP refuerza su potencial práctico para la toma de decisiones en tiempo real.

Asimismo, se exploró el uso de modelos de **análisis de sentimiento preentrenados** como RoBERTa, aplicados sobre los tweets del Huracán María anotados con categorías del conjunto HumAID. Esta integración permitió asociar automáticamente cada tweet con un tono emocional (*positivo*, *neutral*, *negativo*) y un puntaje de confianza. Los resultados evidencian patrones interesantes: clases relacionadas con daños o víctimas mostraron una mayor proporción de sentimiento negativo, mientras que mensajes de apoyo y ayuda tendieron a ser más neutrales o positivos. Esta dimensión emocional añade un valor cualitativo que puede complementar las decisiones humanitarias automatizadas.

Sin embargo, se observaron desafíos persistentes en la clasificación de la clase *no informativo*, la cual presentó consistentemente métricas inferiores en comparación con las otras categorías evaluadas. Esta limitación refleja una dificultad inherente al análisis textual automatizado, específicamente debido a la ambigüedad lingüística y a la menor representatividad de ejemplos disponibles para esta categoría en el conjunto de datos. Esta situación subraya la necesidad de implementar técnicas adicionales de balanceo de clases como *oversampling*, SMOTE o la generación sintética de datos para mejorar el aprendizaje en categorías minoritarias.

Desde una perspectiva aplicada, los resultados destacan la relevancia práctica de desarrollar modelos capaces de operar en tiempo real para apoyar decisiones críticas durante emergencias. La efectividad alcanzada en la clasificación general de tweets informativos tiene implicaciones positivas directas en términos operativos, facilitando respuestas rápidas y precisas en situaciones donde la información oportuna es crucial. Además, los análisis complementarios con Random Forest y RoBERTa demostraron que es posible enriquecer el pipeline tradicional con dimensiones adicionales como el tono emocional y la urgencia percibida del mensaje.

Finalmente, es importante señalar que la interpretabilidad y explicabilidad de los modelos continúa siendo una prioridad esencial. Los resultados obtenidos motivan la futura implementación de técnicas como SHAP o LIME para proporcionar mayor transparencia en las predicciones realizadas, incrementando así la confianza y aceptación por parte de usuarios finales como personal de respuesta a emergencias y comunicadores sociales.

## 9. Conclusiones y Trabajo Futuro

Este proyecto logró desarrollar y evaluar exitosamente modelos automatizados para clasificar tweets relacionados con desastres naturales en Puerto Rico, alcanzando precisiones elevadas y buena capacidad de generalización. La contribución más significativa radica en la validación empírica de una arquitectura neuronal optimizada con técnicas avanzadas de regularización, la cual mostró rendimiento superior frente a modelos clásicos como Naive Bayes, SVM y Regresión Logística.

La integración de múltiples conjuntos de datos ha sido esencial para mejorar la representatividad de los tweets analizados. En particular, el **HumAID Hurricane María Dataset** (3), que incluye anotaciones manuales en categorías humanitarias, permitió el entrenamiento supervisado de modelos de clasificación multiclase. Por otro lado, conjuntos como el **ISCRAM18 Dataset** (2), el **Disaster Tweet Corpus 2020 (DTC2020)** (4) y el **Twitter Disaster Behavior Dataset (VT-TDB)** (1), aunque no etiquetados por clase informativa, resultaron útiles para análisis exploratorios, sentimentales y validaciones cruzadas. Esto resalta la necesidad de seguir ampliando los corpus existentes mediante procesos de anotación manual que habiliten su uso en tareas supervisadas y análisis más finos.

En cuanto al análisis de sentimientos, aunque se emplearon métodos efectivos como VADER, futuras investigaciones podrían beneficiarse sustancialmente de enfoques más avanzados y específicos para el lenguaje informal de redes sociales, como TextBlob (español) y modelos basados en Transfor-

mers adaptados a Twitter, tales como `cardiffnlp/twitter-roberta-base-sentiment-latest`. Estos métodos tienen el potencial de capturar matices emocionales más precisos, incluyendo el uso de emojis y jerga propia de redes sociales.

Para futuras investigaciones, se identifican claramente las siguientes líneas prácticas:

- **Evaluación con Transformers (BERT, RoBERTa):** Incorporar modelos avanzados preentrenados que capturen mejor el contexto y la semántica profunda del texto.
- **Técnicas adicionales de balanceo (SMOTE, Oversampling):** Explorar métodos más efectivos para mejorar el rendimiento en la clase minoritaria (*no informativo*).
- **Ampliación y enriquecimiento de conjuntos de datos etiquetados:** Continuar integrando y anotando manualmente nuevos datasets para mejorar la calidad del entrenamiento supervisado.
- **Análisis avanzado de sentimiento:** Implementar y evaluar modelos como TextBlob y modelos específicos de redes sociales (`cardiffnlp/twitter-roberta-base-sentiment-latest`) para mejorar la caracterización emocional de los tweets.
- **Análisis en tiempo real:** Desarrollar un sistema dinámico que permita la clasificación inmediata durante eventos críticos.
- **Interpretabilidad (SHAP, LIME):** Profundizar en la explicabilidad de los modelos para aumentar la transparencia y facilitar su aceptación por parte de tomadores de decisiones en situaciones críticas.

Estas recomendaciones permitirán no solo refinar la precisión y generalización de los modelos desarrollados, sino también potenciar su utilidad práctica en contextos reales de gestión de emergencias.

## Referencias

- [1] T. Thackaberry, K. Bogemann, S. Burchard, J. Butler, and A. Spencer, "Twitter disaster behavior," Virginia Tech, Tech. Rep., May 2020. [Online]. Available: <http://hdl.handle.net/10919/98251>
- [2] F. Alam, F. Ofli, M. Imran, and M. Aupetit, "A twitter tale of three hurricanes: Harvey, irma, and maria," *arXiv preprint arXiv:1805.05144*, 2018. [Online]. Available: <https://arxiv.org/abs/1805.05144>
- [3] F. Alam, U. Qazi, M. Imran, and F. Ofli, "Humaid: Human-annotated disaster incidents data from twitter with deep learning benchmarks," in *Proceedings of the 15th International Conference on Web and Social Media (ICWSM)*, 2021. [Online]. Available: <https://doi.org/10.1609/icwsml.v15i1.18116>
- [4] M. Wiegmann, J. Kersten, F. Klan, M. Potthast, and B. Stein, "Disaster tweet corpus 2020," Zenodo, Mar. 2020. [Online]. Available: <https://doi.org/10.5281/zenodo.3713920>
- [5] U. Naseem, I. Razzak, M. Khushi, P. W. Eklund, and J. Kim, "COVIDSenti: A large-scale benchmark twitter data set for COVID-19 sentiment analysis," *IEEE Transactions on Computational Social Systems*, vol. 8, no. 4, pp. 1003–1015, 2021.
- [6] Imamah and F. H. Rachman, "Twitter sentiment analysis of COVID-19 using term weighting tf-idf and logistic regression," in *2020 6th Information Technology International Seminar (ITIS)*, 2020, pp. 238–242.
- [7] A. S. Imran, S. M. Daudpota, Z. Kastrati, and R. Batra, "Cross-cultural polarity and emotion detection using sentiment analysis and deep learning on COVID-19 related tweets," *IEEE Access*, vol. 8, pp. 181 074–181 090, 2020.
- [8] Z. Jianqiang and G. Xiaolin, "Comparison research on text pre-processing methods on twitter sentiment analysis," *IEEE Access*, vol. 5, pp. 2870–2879, 2017.
- [9] L.-A. Cotfas, C. Delcea, I. Roxin, C. Ioanăș, D. S. Gherai, and F. Tajariol, "The longest month: Analyzing COVID-19 vaccination opinions dynamics from tweets in the month following the first vaccine announcement," *IEEE Access*, vol. 9, pp. 33 203–33 223, 2021.

## Apéndice: Código fuente

El código completo utilizado en este estudio, incluyendo scripts de preprocesamiento, entrenamiento, análisis de sentimiento y visualización, está disponible públicamente en el siguiente repositorio:

<https://github.com/marcoyuuu/PR-Disaster-Tweets>

Este repositorio contiene documentación técnica y ejemplos de uso reproducibles, facilitando su reutilización y adaptación para investigaciones futuras sobre comunicación digital durante desastres naturales.

### A. Apéndice: Diagrama del Pipeline Metodológico




Figura 14: Pipeline metodológico para el análisis de sentimiento en Twitter durante desastres naturales.

## B. Figuras y Resultados Gráficos




Figura 15: Distribución de categorías humanitarias originales en los tweets del dataset HumAID.




Figura 16: Distribución de tweets por conjunto: train, dev y test.




Figura 17: Distribución de categorías humanitarias por conjunto de datos.




Figura 18: Distribución de clases tras el reagrupamiento de etiquetas.




Figura 19: Nube de palabras generada a partir del corpus preprocesado.




Figura 20: Distribución de longitud de tweets preprocesados por clase.




Figura 21: Matriz de confusión del modelo Naive Bayes con representación BoW (unigramas).




Figura 22: Métricas de evaluación por clase para el modelo Naive Bayes (BoW).




Figura 23: Matriz de confusión del modelo SVM con representación TF-IDF.






Figura 24: Métricas de evaluación por clase para el modelo SVM (TF-IDF).




Figura 25: Matriz de confusión de la Regresión Logística con representación BoW.




Figura 26: Métricas de evaluación por clase para la Regresión Logística (BoW).




Figura 27: Precisión de entrenamiento y validación por época.




Figura 28: Evolución de la pérdida (loss) durante el entrenamiento.




Figura 29: Matriz de confusión obtenida para el modelo neuronal simple.




Figura 30: Precisión, recall y F1-score por clase para la red neuronal simple.




Figura 31: Evolución de la precisión por época (modelo regularizado).




Figura 32: Evolución de la pérdida por época (modelo regularizado).




Figura 33: Matriz de confusión del modelo neuronal con regularización y *dropout*.




Figura 34: Métricas por clase del modelo regularizado: Precisión, Recall y F1-score.




Figura 35: Matrices de confusión para los modelos clásicos sobre el nuevo conjunto de datos.




Figura 36: Métricas por clase (precisión, recall y F1-score) para modelos clásicos.




Figura 37: Evolución de la precisión y pérdida durante el entrenamiento del modelo neuronal mejorado.




Figura 38: Matriz de confusión del modelo neuronal sobre la nueva data.




Figura 39: Comparación de modelos sobre el nuevo conjunto de datos.

## Análisis Complementario: Árboles de Decisión, Noticias y Terremotos




Figura 40: Accuracy por modelo en noticias del Huracán María.




Figura 41: F1-weighted por modelo en noticias del Huracán María.




Figura 42: F1-macro por modelo en noticias del Huracán María.




Figura 43: Accuracy por modelo en noticias de los Terremotos 2020.




Figura 44: F1-weighted por modelo en noticias de los Terremotos 2020.




Figura 45: F1-macro por modelo en noticias de los Terremotos 2020.




Figura 46: Comparación de distribución de sentimiento entre Huracán María y Terremotos 2020.




Figura 47: F1-Macro score por modelo en clasificación de tweets del Huracán María (ISCRAM18).




Figura 48: Accuracy por modelo en clasificación de tweets del Huracán María (ISCRAM18).



## C. Clasificación Supervisada con Random Forest e Ingeniería de Características




Figura 49: F1-Macro Score global obtenido por el modelo (ideal para datasets desbalanceados).




Figura 50: Matrices de confusión del modelo: a la izquierda en valores absolutos, a la derecha en porcentaje normalizado.




Figura 51: Matriz de confusión en valores absolutos: distribución de predicciones correctas e incorrectas.




Figura 52: Matriz de confusión normalizada: porcentajes de predicción por clase.




Figura 53: Precisión, Recall y F1-score por clase. Clase 0: Informativo, 1: Neutral, 2: No Informativo.

#### D. Análisis de Sentimiento con RoBERTa sobre Tweets del Huracán María




Figura 54: Confianza del modelo RoBERTa según el sentimiento predicho en los tweets.




Figura 55: Distribución porcentual de sentimiento por clase temática (HumAID).